

In the print dialog choose "Save as PDF". Turn on "Background graphics" if colours are missing.



SERIES EVALUATION REPORT

Claude: Haiku vs Sonnet vs Opus

Generated 8 Oct 2026, 12:24 · Series by Paweł

4
test cases

3
models

2
repetitions

24
answers

0
human ratings

24
AI ratings


VERDICT

Claude Opus (CLI) wins with an average of 4.8 ★
6 iteration wins · spread σ 0.43 · +0.13 ★ ahead of second place

Model ranking

#	MODEL	AVERAGE	HUMANS	AI	WINS	SPREAD Σ	FAILURES	AVG TIME	AVG TOKENS
1	Claude Opus (CLI) Claude Code CLI · Candidate C	4.8 (8)	—	4.8	6	0.43	0/8	11.7 s	742
2	Claude Sonnet (CLI) Claude Code CLI · Candidate B	4.6 (8)	—	4.6	5	0.48	0/8	7.6 s	544
3	Claude Haiku (CLI) Claude Code CLI · Candidate A	3.1 (8)	—	3.1	0	0.78	0/8	21.6 s	2,094

Average rating (1–5 ★)



Results per test case

Test case	Claude Opus (CLI)	Claude Sonnet (CLI)	Claude Haiku (CLI)
Action items z retrospektywy (JSON)	5.0	4.0	3.0
Klasyfikacja zgłoszeń supportu	5.0	4.5	4.0
Prosty język – pismo urzędowe	5.0	5.0	2.0
Release notes z listy commitów	4.0	5.0	3.5

12345

Average over all repetitions and ratings. Lighter = worse, darker = better.

Test case details

Action items z retrospektywy (JSON)

PROMPT

Z poniższej transkrypcji retrospektywy wyciągnij wszystkie zadania do wykonania. Zwróć WYŁĄCZNIE poprawny JSON w formacie: [{"zadanie": string, "osoba": string | null, "termin": string | null, "priorytet": "wysoki" | "średni" | "niski"}]

Nie dodawaj zadań, których nie było w rozmowie.

<data>

Kasia: Co poszło źle? Deploy w czwartek wywalił się trzy razy przez migracje.

Michał: Bo migracje nie są testowane na kopii produkcji. Mogę do końca przyszłego tygodnia postawić job w CI, który odpala migracje na zanonimizowanym dumpie.

Kasia: Super, bierz. To jest dla nas najważniejsze.

Bartek: Druga rzecz – code review trwa średnio dwa dni. PR-y wiszą.

Kasia: Propozycje?

Bartek: Rotacyjny dyżurny od review, codziennie ktoś inny. Mogę rozpisać grafik.

Kasia: Ok, Bartek rozpisuje do poniedziałku.

Ewa: Dokumentacja API jest nieaktualna, klienci piszą do supportu. Ktoś powinien się tym zająć, ale nie... (truncated)

Claude Haiku (CLI)

rep. 1

3.0 ★

★★★★★ 🐞 AI · Claude Opus (CLI) – Otacza JSON blokiem markdown ``json, co łamie wymóg zwrócenia WYŁĄCZNIE JSON. Zadanie dotyczące dokumentacji zniekształca rozmowę: nikt nie zobowiązał się do jej aktualizacji za tydzień, ustalono jedynie powrót do tematu. Pozostałe zadania, osoby i terminy są poprawne.

Claude Haiku (CLI)

rep. 2

3.0 ★

★★★★★ 🐞 AI · Claude Opus (CLI) – JSON opakowano w bloki markdown, choć polecenie wymagało wyłącznie JSON. Zadanie dotyczące dokumentacji przeinaczono na „Zaktualizowanie dokumentacji API”, podczas gdy ustalono jedynie powrót do tematu za tydzień. Przeliczenie terminów na daty jest spójne z dzisiejszą datą, ale opisy zadań są uboższe niż w pozostałych odpowiedziach.

Claude Sonnet (CLI)

rep. 1

4.0 ★

★★★★★ 🐞 AI · Claude Opus (CLI) – Zwraca czysty JSON z poprawnie ujętymi czterema głównymi zadaniami, a dokumentację trafnie opisuje jako powrót do tematu. Dodaje jednak punkt o kontynuowaniu pair programmingu, który jest raczej obserwacją z retrospektywy niż konkretnym zadaniem do wykonania.

Claude Sonnet (CLI)

rep. 2

4.0 ★

★★★★★ 🐞 AI · Claude Opus (CLI) – Poprawny czysty JSON, a cztery główne zadania mają trafne osoby, terminy i priorytety. Dodano jednak „kontynuowanie pair programmingu” przypisane Ewie, choć była to pozytywna obserwacja, a nie przydzielone zadanie. Osoba w tym punkcie jest więc nadinterpretacją.

Claude Opus (CLI)

rep. 1

5.0 ★

★★★★★ 🐞 AI · Claude Opus (CLI) – Zwraca czysty, poprawny JSON bez dodatków i zawiera wszystkie cztery zadania z właściwymi osobami i terminami. Dokumentację API trafnie opisuje jako powrót do tematu za tydzień i ustalenie osoby, bez wymyślania zobowiązania. Priorytety są sensowne, migracje słusznie oznaczone jako najważniejsze.

Claude Opus (CLI)

rep. 2

5.0 ★

★★★★★ 🤖 AI · Claude Opus (CLI) – Czysty, poprawny JSON z czterema zadaniami wiernie odzwierciedlającymi rozmowę. Osoby, terminy i priorytety są trafne (migracje jako „wysoki”), a dokumentację słusznie ujęto jako powrót do tematu bez przypisanej osoby. Nie dodano niczego spoza rozmowy.

Klasyfikacja zgłoszeń supportu**PROMPT**

Sklasyfikuj każde zgłoszenie do jednej kategorii: BŁĄD, PYTANIE, PROŚBA_O_FUNKCJĘ, PŁATNOŚCI, KONTO, SPAM.
Dodaj pilność: P1 (blokuje pracę wielu osób), P2 (blokuje jedną osobę), P3 (reszta).
Format odpowiedzi: tabela markdown z kolumnami: #, kategoria, pilność, uzasadnienie (max 10 słów).

<data>

1. Od rana nikt w firmie nie może się zalogować, wywala błąd 502.
2. Czy da się wyeksportować raport do Excela?
3. Pobraliście mi dwa razy opłatę za październik!!!
4. Fajnie by było, gdyby był tryb ciemny.
5. Zmieniłam nazwisko po ślubie, jak zaktualizować dane na koncie?
6. Przycisk "Zapisz" w formularzu faktury nic nie robi, nie mogę wystawić faktury klientowi który czeka.
7. CONGRATULATIONS!!! You won iPhone 17, click here to claim
8. Po aktualizacji wykresy na dashboardzie pokazują dane sprzed tygodnia, ale da się pracować.

</data>

Claude Haiku (CLI)

rep. 1

4.0 ★

★★★★★ 🤖 AI · Claude Opus (CLI) – Kategorie są trafne, a uzasadnienia mieszczą się w limicie. Zgłoszenie 3 dostało jednak P2, choć podwójna opłata nie blokuje pracy, więc według podanych definicji powinno być P3. Nazwy kolumn mają też inną wielkość liter niż w poleceniu.

Claude Haiku (CLI)

rep. 2

4.0 ★

★★★★★ 🤖 AI · Claude Opus (CLI) – Kategorie są poprawne, ale zgłoszenie 3 dostało P2, choć podwójna opłata nie blokuje pracy, a uzasadnienie „problem finansowy” nie spełnia definicji P2. Nagłówek dodany nad tabelą to drobny nadmiar.

Claude Sonnet (CLI)

rep. 1

4.0 ★

★★★★★ 🤖 AI · Claude Opus (CLI) – Kategorie i format są poprawne, uzasadnienia są zwięzłe. Zgłoszenie 3 oznaczono jako P2 z uzasadnieniem „dotyczy jednego klienta”. To nie jest blokada pracy, więc według definicji powinno być P3.

Claude Sonnet (CLI)

rep. 2

5.0 ★

★★★★★ 🤖 AI · Claude Opus (CLI) – Wszystkie kategorie i pilności są poprawne, także P3 dla podwójnej opłaty, bo nie blokuje ona pracy. Format tabeli i limit 10 słów w uzasadnieniu zostały zachowane.

Claude Opus (CLI)

rep. 1

5.0 ★

★★★★★ 🤖 AI · Claude Opus (CLI) – Wszystkie kategorie są poprawne, uzasadnienia mieszczą się w limicie 10 słów, a kolumny mają wymagane nazwy. Zgłoszenie 3 słusznie dostało P3, bo podwójna opłata nie blokuje pracy, a definicja P2 mówi o blokowaniu.

Claude Opus (CLI)

rep. 2

5.0 ★

★★★★★ 🤖 AI · Claude Opus (CLI) – Klasyfikacja i pilności są w pełni zgodne z definicjami. Uzasadnienia są trafne, np. wprost wskazują, że podwójna opłata nie blokuje pracy, i mieszczą się w limicie słów.

Prosty język – pismo urzędowe

PROMPT

Przepisz poniższy tekst prostym językiem, tak żeby zrozumiała go osoba bez wykształcenia prawniczego. Zachowaj wszystkie istotne terminy i kwoty. Na końcu dodaj sekcję „Co muszę zrobić?” w punktach.

<data>

Na podstawie art. 21 ust. 1 ustawy z dnia 13 września 1996 r. o utrzymaniu czystości i porządku w gminach, w związku z uchwałą Rady Miejskiej nr XII/145/2025, uprzejmie zawiadamia się, iż z dniem 1 stycznia 2026 r. stawka opłaty za gospodarowanie odpadami komunalnymi ulega zmianie i wynosi 38,00 zł miesięcznie od osoby zamieszkującej nieruchomość. Właściciele nieruchomości kompostujący bioodpady w kompostowniku przydomowym uprawnieni są do zwolnienia w części z opłaty w wysokości 4,00 zł od osoby, pod warunkiem złożenia stosownej deklaracji w terminie 14 dni od dnia powstania zmiany. Niezłożenie deklaracji skutkuje naliczeniem opłaty w wysokości pełnej. Opłatę uiszcza się bez wezwania... (truncated)

Claude Haiku (CLI)

rep. 1

2.0 ★

★★★★★ 🤖 AI · Claude Opus (CLI) – Odpowiedź pomija podstawę prawną i numer uchwały, choć polecenie wymagało zachowania istotnych terminów. Zawiera też błędy językowe („Opłata za odpadami”, „za to, żeby odbiór”). Termin 14 dni błędnie liczy od 1 stycznia (do 15 stycznia), a nie od dnia powstania zmiany. Zdanie „nic nie musisz robić” wprowadza w błąd, bo trzeba samodzielnie płacić.

Claude Haiku (CLI)

rep. 2

2.0 ★

★★★★★ 🤖 AI · Claude Opus (CLI) – Odpowiedź błędnie interpretuje termin 14 dni jako liczony od 1 stycznia 2026 r., a w źródle chodzi o 14 dni od powstania zmiany. Pomija numer uchwały i podstawę prawną, choć polecenie każe zachować istotne terminy. Zawiera też błędy językowe: cyrylicę w słowie „whocisz”, „Płacaj” i „opłata za odpadami”.

Claude Sonnet (CLI)

rep. 1

5.0 ★

★★★★★ 🤖 AI · Claude Opus (CLI) – Tekst jest prosty i zachowuje wszystkie terminy, kwoty, podstawę prawną oraz numer uchwały. Wiernie oddaje niejasny zapis o 14 dniach od zmiany i nie dopowiada konkretnej daty. Sekcja „Co muszę zrobić?” jest poprawna, a uwaga o obecnej dacie (październik 2026) jest trafna.

Claude Sonnet (CLI)

rep. 2

5.0 ★

★★★★★ 🤖 AI · Claude Opus (CLI) – Odpowiedź poprawnie i prostym językiem oddaje wszystkie kwoty, terminy, numer uchwały i podstawę prawną. Dobrze wyjaśnia termin 14 dni od zmiany, a sekcja „Co muszę zrobić?” jest w punktach. Uwaga o dzisiejszej dacie jest trafna, choć nieco spekulatywna.

Claude Opus (CLI)

rep. 1

5.0 ★

★★★★★ 🤖 AI · Claude Opus (CLI) – Tekst jest prosty, z praktycznymi przykładami obliczeń, i zachowuje podstawę prawną, numer uchwały oraz wszystkie kwoty. Poprawnie wyjaśnia, że 14 dni liczy się od zmiany, np. od rozpoczęcia kompostowania. Lista „Co muszę zrobić?” jest kompletna i przydatna, m.in. z radą o zmianie zlecenia stałego.

Claude Opus (CLI)

rep. 2

5.0 ★

★★★★★ 🤖 AI · Claude Opus (CLI) – Odpowiedź jest bardzo przystępna, z przykładami obliczeń, zachowuje wszystkie kwoty, terminy i odniesienia prawne. Termin 14 dni zinterpretowano poprawnie. Praktyczna lista działań zawiera rozsądne dodatki, np. zmianę zlecenia stałego i kontakt z urzędem.

Release notes z listy commitów

PROMPT

Na podstawie listy commitów napisz release notes dla użytkowników końcowych (nie programistów). Pogrupuj na: Nowości, Poprawki, Inne. Pomiń zmiany czysto techniczne, które nie wpływają na użytkownika.

```
<data>
a1f3c2e feat(invoices): bulk export to PDF (#812)
9bd2e10 fix(auth): session expired too early on mobile Safari
77c01aa chore(deps): bump Npgsql 9.0.3 -> 9.0.4
e22fa01 feat(dashboard): dark mode toggle
5c9e8f3 refactor(core): extract PriceCalculator
0a13bd7 fix(invoices): VAT rounding off by 0.01 for multi-line invoices
d4e5f6a ci: cache nuget packages
3f3f3f1 feat(notifications): email digest daily/weekly setting
8e8e8e2 fix(search): polish diacritics ignored in customer search
1b2b3b4 test: add integration tests for invoice export
</data>
```

Claude Haiku (CLI)

rep. 1

3.0 ★

★★★★★ 🤖 AI · Claude Opus (CLI) – Wszystkie zmiany istotne dla użytkownika są ujęte, a techniczne pominięte. Są jednak błędy językowe („gestu emailowego” zamiast podsumowania, „toggle przełącznika dark mode'u”) i żargon nieodpowiedni dla użytkowników końcowych. Brakuje sekcji „Inne”, a data aktualizacji nie wynika z danych.

Claude Haiku (CLI)

rep. 2

4.0 ★

★★★★★ 🤖 AI · Claude Opus (CLI) – Grupowanie jest poprawne i kompletne, a zmiany techniczne pominięto. Zostały jednak żargon („toggle”), niezręczne „pulpit nawigacyjny” oraz nieuzasadnione założenie waluty ($\pm 0,01$ PLN). Sekcja Inne zawiera tylko formułkę o braku informacji.

Claude Sonnet (CLI)

rep. 1

5.0 ★

★★★★★ 🤖 AI · Claude Opus (CLI) – Poprawnie pogrupowano zmiany, język jest prosty i przyjazny dla użytkownika, a zmiany techniczne pominięto z krótką adnotacją. Sekcja „Inne” jest obecna, choć pusta. Przykład „Łukasz/Lukasz” to drobna interpretacja, ale nie przeinacza poprawki.

Claude Sonnet (CLI)

rep. 2

5.0 ★

★★★★★ 🤖 AI · Claude Opus (CLI) – Release notes są poprawne, kompletne i napisane prostym językiem dla użytkownika. Prawidłowo pogrupowano Nowości i Poprawki, a refaktoryzację, CI, testy i aktualizację biblioteki słusznie pominięto. Nie ma zmyślonych dodatków ani zbędnego wypełniacza.

Claude Opus (CLI)

rep. 1

4.0 ★

★★★★★ 🤖 AI · Claude Opus (CLI) – Opisy są jasne i dobrze dopasowane do użytkowników końcowych. Sekcja „Inne” zawiera jednak ogólnik o „stabilności i niezawodności”, który częściowo przeczy poleceniu pominięcia zmian technicznych i nie wynika z commitów. Dodano też drobne ulepszenia („jednym kliknięciem”, „mniej męczy wzrok”).

Claude Opus (CLI)

rep. 2

4.0 ★

★★★★★ 🤖 AI · Claude Opus (CLI) – Wszystkie zmiany widoczne dla użytkownika są poprawnie pogrupowane i opisane przystępnym językiem, a pozycje techniczne słusznie pominięto. Przejrzysto wyjaśniono też, co i dlaczego pominięto. Minusem jest wpis „Drobne usprawnienia działania i stabilności” w sekcji Inne, który jest ogólnikowym wypełniaczem słabo popartym danymi.

Methodology

Every test case was run on all models, in a random order in each iteration. Raters – humans and AI judges – saw the answers only as “Model 1, 2...”, never the model names. AI judges received the prompt, the expected answer (if any) and the anonymous answers. A “win” is the highest average in an iteration (ties count for everyone on top). Spread σ is the standard deviation of a model’s per-answer average ratings.

AI judges: Claude Opus (CLI).

LLM Eval Studio · 8 Oct 2026, 12:24